TDE #3

Filipe J. Zabala

2024-11-06

NOMES	COMPLETOS:	
INCIMES	COMETELLOS:	

Instruções

- 1. Entrega até 2024-11-25.
- 2. Tamanho do grupo: até 3 pessoas.
- 3. Entregue a resolução via Moodle, indicando o(s) nome(s) completo(s) e a turma no cabeçalho do documento.

Questões

X2

X3

- **Q1**. (3.0) Foi observada uma amostra de clientes, que opiniaram com notas de a 10 sobre um serviço prestado. Considere X1: pontualidade, X2: conhecimento e X3: disponibilidade.
- a. (0.5) Defina $n \in p$ a partir das informações do BLOCO 1A.
- b. (0.5) Indique o que são as medidas intituladas Medida 1, Medida 2 e Medida 3, calculadas no BLOCO 1B.
- c. (0.5) Apresente o passo-a-passo de como é calculado o valor -0.1889822 da matriz R e interprete-o.
- d. (0.5) No BLOCO 1C indique os testes que estão sendo realizados, suas hipóteses H_0 e H_1 e qual a sua decisão em cada um deles considerando $\alpha = 5\%$.
- e. (0.5) No BLOCO 1D indique qual teste está sendo realizado, quais as hipóteses H_0 e H_1 e qual sua decisão considerando $\alpha = 5\%$.
- f. (0.5) Quais diferenças você identifica entre os testes realizados nos blocos 1C e 1D?

```
X <- read.table('https://filipezabala.com/data/clientes.txt',</pre>
                  header = TRUE, sep = '\t')
t(X)
##
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
## X1
         6
              10
                   10
                          7
                               7
                                     4
                                         10
                                                5
                                                     8
                                                            7
                                                                 10
```

```
# BLOCO 1B
(m <- colMeans(X)) # Medida 1</pre>
## X1 X2 X3
## 7.5 9.0 4.0
(S <- cov(X))
                 # Medida 2
                         X2
                                    ХЗ
              Х1
## X1 4.4545455 -0.7272727 2.0000000
## X2 -0.7272727 0.7272727 -0.1818182
## X3 2.0000000 -0.1818182 1.2727273
(R <- cor(X))
                 # Medida 3
                                    ХЗ
##
              Х1
                         X2
## X1 1.0000000 -0.4040610 0.8399639
## X2 -0.4040610 1.0000000 -0.1889822
## X3 0.8399639 -0.1889822 1.0000000
# BLOCO 1C
t.test(X$X1, mu = 8)
##
##
  One Sample t-test
##
## data: X$X1
## t = -0.82065, df = 11, p-value = 0.4293
## alternative hypothesis: true mean is not equal to 8
## 95 percent confidence interval:
## 6.159002 8.840998
## sample estimates:
## mean of x
##
         7.5
t.test(X$X2, mu = 8)
##
## One Sample t-test
##
## data: X$X2
## t = 4.062, df = 11, p-value = 0.001877
## alternative hypothesis: true mean is not equal to 8
## 95 percent confidence interval:
## 8.458155 9.541845
## sample estimates:
## mean of x
t.test(X$X3, mu = 8)
##
  One Sample t-test
##
## data: X$X3
## t = -12.282, df = 11, p-value = 9.156e-08
## alternative hypothesis: true mean is not equal to 8
## 95 percent confidence interval:
```

```
## 3.283206 4.716794
## sample estimates:
## mean of x
## 4

#BLOCO 1D

ICSNP::HotellingsT2(X, mu = c(8,8,8))

##
## Hotelling's one sample T2-test
##
## data: X
## T.2 = 158.1, df1 = 3, df2 = 9, p-value = 4.213e-08
## alternative hypothesis: true location is not equal to c(8,8,8)
```


- **Q2**. **(2.5)** (He, Zhang, and Zhang 2016) utilizaram a fluorescência de raios-X (*ED-XRF*) para determinar a composição química de cerâmicas antigas, detalhadas no banco de dados Composição Química de Amostras Cerâmicas¹.
- a. (0.5) Considerando os métodos 'wss' (within sums of squares) e 'silhouette' do BLOCO 2B, determine k, o número ótimo de clusters.
- b. (0.5) Utilizando o resultado do item anterior, circule no BLOCO 2C com lápis, caneta ou virtualmente os k grupos determinados no item anterior.
- c. (0.5) Explique o que ocorre nos comandos prcomp(dat[,-(1:2)]) e prcomp(dat[,-(1:2)], scale = TRUE) do BLOCO 2D.
- \mathbf{d} . (0.5) Coloque em ordem decrescente as três variáveis com maior contribuição para a PC1, usando a saída do BLOCO 2D.
- e. (0.5) Considerando o gráfico das duas primeira componentes principais do BLOCO 2E, você considera que estas duas dimensões são úteis para diferenciar as partes da cerâmica (Body/Glaze ou Corpo/Verniz)? Que pontos de corte você sugere em cada dimesão dos gráficos?

```
# BLOCO 2A
dat <- read.csv('https://filipezabala.com/data/ceramic.csv', head = T)</pre>
dplyr::glimpse(dat)
## Rows: 88
## Columns: 19
## $ Ceramic.Name <chr> "FLQ-1-b", "FLQ-2-b", "FLQ-3-b", "FLQ-4-b", "FLQ-5-b", "F-
                  <chr> "Body", "Body", "Body", "Body", "Body", "Body", "A
## $ Part
                  <dbl> 0.62, 0.57, 0.49, 0.89, 0.03, 0.62, 0.45, 0.59, 0.42, 0.5~
## $ Na20
## $ MgO
                  <dbl> 0.38, 0.47, 0.19, 0.30, 0.36, 0.18, 0.33, 0.45, 0.53, 0.4~
## $ A1203
                  <dbl> 19.61, 21.19, 18.60, 18.01, 18.41, 18.82, 17.65, 21.42, 2~
## $ SiO2
                  <dbl> 71.99, 70.09, 74.70, 74.19, 73.99, 73.79, 74.99, 71.46, 6~
## $ K20
                  <dbl> 4.84, 4.98, 3.47, 4.01, 4.33, 4.28, 3.53, 3.47, 3.81, 4.5~
                  <dbl> 0.31, 0.49, 0.43, 0.27, 0.65, 0.30, 0.70, 0.35, 0.74, 0.2~
## $ CaO
## $ TiO2
                  <dbl> 0.07, 0.09, 0.06, 0.09, 0.05, 0.04, 0.07, 0.05, 0.16, 0.2~
## $ Fe203
                  <dbl> 1.18, 1.12, 1.07, 1.23, 1.19, 0.96, 1.28, 1.20, 2.81, 1.1~
## $ MnO
                  <int> 630, 380, 420, 460, 380, 350, 650, 500, 340, 330, 320, 42~
                  <int> 10, 20, 20, 20, 40, 20, 20, 10, 40, 20, 70, 0, 50, 0, 40,~
## $ CuO
## $ ZnO
                  <int> 70, 80, 50, 70, 90, 80, 90, 70, 120, 70, 40, 90, 100, 100~
## $ Pb02
                  <int> 10, 40, 50, 60, 40, 10, 90, 50, 30, 20, 20, 30, 10, 90, 2~
                  <int> 430, 430, 380, 380, 360, 390, 410, 380, 370, 350, 450, 43~
## $ Rb20
## $ SrO
                  <int> 0, -10, 40, 10, 10, 10, 30, 70, 20, 10, 10, 10, 30, 20, 1~
## $ Y203
                  <int> 40, 40, 40, 40, 30, 40, 30, 40, 30, 40, 40, 40, 30, 50, 5~
## $ ZrO2
                  <int> 80, 100, 80, 70, 80, 80, 90, 80, 150, 130, 120, 80, 80, 2~
                  <int> 90, 110, 200, 210, 150, 130, 140, 440, 180, 150, 140, 100~
## $ P205
```

¹https://archive.ics.uci.edu/ml/datasets/Chemical+Composition+of+Ceramic+Samples


```
# BLOCO 2B
dat_sc <- scale(dat[,-(1:2)])
p1 <- factoextra::fviz_nbclust(dat_sc, kmeans, method = 'wss')
p2 <- factoextra::fviz_nbclust(dat_sc, kmeans, method = 'silhouette')
gridExtra::grid.arrange(p1, p2, ncol = 2, heights = grid::unit(8, c('cm')))</pre>
```

Optimal number of clusters 1500 1500 1250 1000 1 2 3 4 5 6 7 8 9 10 Number of clusters k




BLOCO 2C

Cluster Dendrogram



```
# BLOCO 2D
cp <- prcomp(dat[,-(1:2)])</pre>
cp_sc <- prcomp(dat[,-(1:2)], scale = TRUE)</pre>
cp_sc$rotation[,1:5]
##
                 PC1
                               PC2
                                             PC3
                                                           PC4
                                                                       PC5
## Na20
         -0.05483195 -0.314469753
                                    0.237672805
                                                  0.503819096
                                                                0.10825114
## MgO
         -0.20226122 0.278199509
                                   0.107852777
                                                  0.089277827
                                                                0.12741566
## Al203 0.37313171
                      0.100440809 -0.004056619 -0.056817303
                                                                0.01186507
```

```
-0.13694588 -0.372534736 -0.231856245 -0.109454315 -0.44653673
## Si02
## K20
        0.07173101 -0.002766595 -0.420006430
                                      0.196084190
                                                 0.59864515
## Ca0
       -0.36096192  0.107597943  0.165020003  0.006834913
                                                 0.12518019
## TiO2
        ## Fe203 0.27181505 0.218608366 0.313154202 0.276665910 0.08790755
                 0.217667918 -0.224758953 0.115220934
## MnO
       -0.30431777
                                                 0.12826242
## CuO
       -0.05636868 0.086801188 -0.048335602 0.657284732 -0.24814034
       -0.04625579 0.364465222 -0.359421275 0.203704566 -0.35982559
## Zn0
## Pb02
       ## Rb20
       0.26154816 -0.309094340 -0.167713312 0.156814841 0.15207618
       -0.34865074 0.180487805 -0.056219645 -0.160701698 0.08200965
## Sr0
## Y203
        0.25823120 \quad 0.204640640 \quad -0.205111805 \quad -0.096323115
                                                 0.24370097
        ## Zr02
## P205
      -0.34664031 0.138657897 0.177296428 0.050895887
                                                 0.11627896
```



Q3. (2.5) Ainda com os dados da Questão 2, responda os itens a seguir considerando as informações dos Blocos.

- **a.** (0.5) Detalhe o que ocorre no Bloco 3A.
- b. (0.5) O que você diria a respeito do modelo fit0 apresentado no Bloco 3B?
- \mathbf{c} . (0.5) O que você diria a respeito da predição do Bloco 3C?
- **d**. (0.5) Detalhe o que ocorre no Bloco 3D.
- ${f e}$. (0.5) O que você diria a respeito da predição do ${f Bloco}$ 3E? Compare com a predição do item ${f c}$.

```
# BLOCO 3A
dat$v <- 1
dat$y[dat$Part == 'Glaze'] <- 0</pre>
dat$y <- (dat$y)
table(dat$Part, dat$y)
##
##
           0
              1
##
           0 44
    Body
    Glaze 44
dplyr::glimpse(dat)
## Rows: 88
## Columns: 20
## $ Ceramic.Name <chr> "FLQ-1-b", "FLQ-2-b", "FLQ-3-b", "FLQ-4-b", "FLQ-5-b", "F-
## $ Part
                 <chr> "Body", "Body", "Body", "Body", "Body", "Body", "A
                 <dbl> 0.62, 0.57, 0.49, 0.89, 0.03, 0.62, 0.45, 0.59, 0.42, 0.5~
## $ Na20
## $ MgO
                 <dbl> 0.38, 0.47, 0.19, 0.30, 0.36, 0.18, 0.33, 0.45, 0.53, 0.4~
                 <dbl> 19.61, 21.19, 18.60, 18.01, 18.41, 18.82, 17.65, 21.42, 2~
## $ A1203
                 <dbl> 71.99, 70.09, 74.70, 74.19, 73.99, 73.79, 74.99, 71.46, 6~
## $ SiO2
## $ K20
                 <dbl> 4.84, 4.98, 3.47, 4.01, 4.33, 4.28, 3.53, 3.47, 3.81, 4.5~
                 <dbl> 0.31, 0.49, 0.43, 0.27, 0.65, 0.30, 0.70, 0.35, 0.74, 0.2~
## $ CaO
                 <dbl> 0.07, 0.09, 0.06, 0.09, 0.05, 0.04, 0.07, 0.05, 0.16, 0.2~
## $ TiO2
## $ Fe203
                 <dbl> 1.18, 1.12, 1.07, 1.23, 1.19, 0.96, 1.28, 1.20, 2.81, 1.1~
                 <int> 630, 380, 420, 460, 380, 350, 650, 500, 340, 330, 320, 42~
## $ MnO
                 <int> 10, 20, 20, 20, 40, 20, 20, 10, 40, 20, 70, 0, 50, 0, 40,~
## $ CuO
## $ ZnO
                 <int> 70, 80, 50, 70, 90, 80, 90, 70, 120, 70, 40, 90, 100, 100~
                 <int> 10, 40, 50, 60, 40, 10, 90, 50, 30, 20, 20, 30, 10, 90, 2~
## $ Pb02
## $ Rb20
                 <int> 430, 430, 380, 380, 360, 390, 410, 380, 370, 350, 450, 43~
## $ SrO
                 <int> 0, -10, 40, 10, 10, 10, 30, 70, 20, 10, 10, 10, 30, 20, 1~
## $ Y203
                 <int> 40, 40, 40, 40, 30, 40, 30, 40, 30, 40, 40, 40, 30, 50, 5~
                 <int> 80, 100, 80, 70, 80, 80, 90, 80, 150, 130, 120, 80, 80, 2~
## $ ZrO2
## $ P205
                 <int> 90, 110, 200, 210, 150, 130, 140, 440, 180, 150, 140, 100~
## $ y
                 set.seed(4); itrain <- sort(sample(1:nrow(dat), floor(.6*nrow(dat))))</pre>
train <- dat[itrain,-(1:2)]</pre>
test <- dat[-itrain,-(1:2)]</pre>
```


```
fit0 <- glm(y ~ ., data = train, family = 'binomial')</pre>
## Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred
summary(fit0)
##
## Call:
## glm(formula = y ~ ., family = "binomial", data = train)
## Coefficients:
                Estimate Std. Error z value Pr(>|z|)
##
## (Intercept) 2.273e+04 8.947e+08
              -2.403e+02 9.098e+06
## Na20
                                          0
## MgO
              -2.359e+02 9.209e+06
                                          0
## Al203
              -2.268e+02 9.036e+06
                                          0
                                                   1
## SiO2
              -2.295e+02 9.037e+06
                                          0
## K20
              -2.359e+02 9.067e+06
                                          0
                                                   1
## CaO
              -2.338e+02 9.029e+06
                                          0
                                                   1
## TiO2
              -2.342e+02 8.875e+06
                                          0
                                                   1
## Fe203
              -2.298e+02 8.990e+06
                                          0
                                                   1
              4.306e-04 3.951e+02
## MnO
                                          0
                                                   1
              -5.109e-02 3.432e+03
## CuO
                                          0
                                                   1
                                          0
## Zn0
              2.671e-02 2.562e+03
                                                   1
## Pb02
              1.095e-02 5.345e+03
                                          0
                                                   1
## Rb20
               1.576e-02 2.290e+03
                                          0
                                                   1
## Sr0
              -1.143e-02 1.303e+03
                                          0
                                                   1
## Y203
               1.307e-01 9.269e+03
                                          0
                                                   1
## Zr02
              -4.609e-02 4.338e+03
                                          0
                                                   1
## P205
               8.299e-03 3.818e+02
                                          0
##
## (Dispersion parameter for binomial family taken to be 1)
##
      Null deviance: 7.2010e+01 on 51 degrees of freedom
## Residual deviance: 4.1743e-10 on 34 degrees of freedom
## AIC: 36
##
## Number of Fisher Scoring iterations: 25
mctest::mctest(fit0)
##
## Call:
## omcdiag(mod = mod, Inter = TRUE, detr = detr, red = red, conf = conf,
##
       theil = theil, cn = cn)
##
## Overall Multicollinearity Diagnostics
##
##
                           MC Results detection
## Determinant |X'X|:
                               0.0000
## Farrar Chi-Square:
                            1152.1125
                                              1
## Red Indicator:
                               0.3692
## Sum of Lambda Inverse: 1120772.2819
```


```
## Theil's Method:
                                -1.2115
## Condition Number:
                           69978.2618
## 1 --> COLLINEARITY is detected by the test
## 0 --> COLLINEARITY is not detected by the test
sort(car::vif(fit0), decreasing = TRUE)
                                                                                Na20
                                                     K20
                                                                 Fe203
##
          A1203
                          CaO
                                       Si02
## 6.875856e+05 6.083616e+05 2.458227e+05 2.416777e+04 1.148067e+04 5.531171e+03
            MgO
                         TiO2
                                       SrO
                                                     MnO
                                                                  ZrO2
                                                                                Rb20
## 1.376311e+03 1.067401e+02 5.109480e+01 2.552851e+01 1.975223e+01 1.528506e+01
           Pb02
                         P205
                                      Y203
                                                     Zn0
## 1.367754e+01 9.331493e+00 6.219689e+00 3.695851e+00 2.500136e+00
# BLOCO 3C
pred <- round(predict(fit0, test, type = 'response'))</pre>
(cm <- table(test$y, pred))</pre>
##
      pred
##
        0 1
     0 19 0
     1 0 17
##
# BLOCO 3D
pc \leftarrow prcomp(dat[,-c(1:2,20)], scale = TRUE)
train_pc <- cbind(train['y'], pc1 = pc$x[itrain,1])</pre>
train_pc <- cbind(train_pc, pc2 = pc$x[itrain,2])</pre>
test_pc <- cbind(test['y'], pc1 = pc$x[-itrain,1])</pre>
test_pc <- cbind(test_pc, pc2 = cp$x[-itrain,2])</pre>
fit1 <- glm(y ~ ., data = train_pc, family = 'binomial')</pre>
# BLOCO 3E
pred <- round(predict(fit1, test_pc, type = 'response'))</pre>
(cm <- table(test_pc$y, pred))</pre>
##
      pred
        0 1
##
##
     0 11 8
   1 1 16
##
```

Q4. (2.0) No Capítulo 12, Dalgaard (2008) utiliza a base de dados cystfibr, um banco de dados sobre capacidade respiratória discutido por Altman (1991)². Abaixo estão as descrições das variáveis observadas, com volumes indicados em decilitros.

- idade: idade em anos
- sexo: 0 = masculino, 1 = feminino
- imc: Índice de Massa Corporal (Peso/Altura²) como um percentual da mediana de indivíduos normais por idade
- vef1: Volume de Expiração Forçado em 1 segundo
- vr: Volume Residual, o volume restante de ar nos pulmões após uma expiração forçada
- crf: Capacidade Residual Funcional, o volume nos pulmões ao final da posição normal de expiração
- cpt: Capacidade Pulmonar Total
- pemax: Pressão expiratória estática máxima, variável dependente que indica a saúde do sistema respiratório (maior, melhor)
- a. (0.5) Explique o que os gráficos do BLOCO A indicam. O que significam os percentuais nos eixos?
- b. (0.5) Indique o que ocorre nos BLOCOS B, C e D, explicando também a relação entre eles.
- ${f c.}$ (0.5) Aponte duas melhorias do modelo do BLOCO ${f E}$ em relação ao modelo do BLOCO ${f D.}$
- d. (0.5) Interprete os coeficientes estimados no modelo do BLOCO E.

BLOCO A





```
# BLOCO B
fit0 <- lm(pemax ~ ., data = cystfibr)
summary(fit0)</pre>
```

```
##
## Call:
## lm(formula = pemax ~ ., data = cystfibr)
```

²Practical Statistics for Medical Research, Tabela 12.11, Chapman & Hall.

```
##
## Residuals:
      Min
                1Q Median
## -38.776 -17.540
                    3.971 14.584 36.241
## Coefficients:
              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -10.1121
                        185.0664 -0.055
                                              0.957
## idade
               -0.4131
                           4.6791 -0.088
                                              0.931
## sexo1
                          16.4014 -0.267
               -4.3718
                                              0.793
## altura
                0.1883
                           0.8511
                                    0.221
                                              0.828
## peso
                1.2040
                           1.4592
                                    0.825
                                              0.422
## imc
               -0.3796
                           0.5801 -0.654
                                              0.523
## vef1
                0.8295
                           1.1885
                                    0.698
                                              0.496
## vr
                0.2593
                            0.2040
                                     1.271
                                              0.223
## crf
                -0.4793
                            0.5165 -0.928
                                              0.368
## tlc
                0.5349
                            0.4802
                                     1.114
                                              0.283
##
## Residual standard error: 26.94 on 15 degrees of freedom
## Multiple R-squared: 0.599, Adjusted R-squared: 0.3584
## F-statistic: 2.49 on 9 and 15 DF, p-value: 0.05706
# BLOCO C
sort(car::vif(fit0), decreasing = TRUE)
                 idade
                                    altura
                                                                               tlc
       peso
                             crf
                                                          vef1
                                                  vr
                                                                    sexo
## 22.558732 18.531407 16.863994 11.073274 10.179948 5.856733 2.283452
        imc
## 1.848716
mctest::mctest(fit0)
##
## Call:
## omcdiag(mod = mod, Inter = TRUE, detr = detr, red = red, conf = conf,
##
      theil = theil, cn = cn)
##
## Overall Multicollinearity Diagnostics
##
##
                          MC Results detection
## Determinant |X'X|:
                              0.0001
                                             1
## Farrar Chi-Square:
                            196.1884
## Red Indicator:
                              0.5099
## Sum of Lambda Inverse:
                             91.3916
                                             1
## Theil's Method:
                              2.2567
## Condition Number:
                            125.4905
##
## 1 --> COLLINEARITY is detected by the test
## 0 --> COLLINEARITY is not detected by the test
# BLOCO D
fit1 <- step(fit0, trace=0)</pre>
summary(fit1)
```

##

```
## Call:
## lm(formula = pemax ~ peso + vef1 + vr + crf + tlc, data = cystfibr)
##
## Residuals:
##
                1Q Median
                                3Q
                                       Max
## -38.310 -16.724
                    0.722 19.260
                                    32.688
## Coefficients:
##
               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -32.0892
                           57.1098 -0.562 0.58076
## peso
                 1.2631
                            0.3626
                                     3.484 0.00248 **
                 0.9593
                                     1.567 0.13358
## vef1
                            0.6121
## vr
                 0.3113
                            0.1483
                                     2.099 0.04940 *
## crf
                -0.5624
                            0.3289
                                    -1.710 0.10351
                 0.5943
                            0.4234
                                     1.404 0.17653
## tlc
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 24.58 on 19 degrees of freedom
## Multiple R-squared: 0.5772, Adjusted R-squared: 0.4659
## F-statistic: 5.187 on 5 and 19 DF, p-value: 0.003615
# BLOCO E
fit2 <- lm(formula = pemax ~ peso + vef1 + vr - 1, data = cystfibr)</pre>
summary(fit2)
##
## Call:
## lm(formula = pemax ~ peso + vef1 + vr - 1, data = cystfibr)
##
## Residuals:
##
     Min
              1Q Median
                            3Q
                                  Max
## -44.71 -18.10 -0.36 19.39 41.44
##
## Coefficients:
       Estimate Std. Error t value Pr(>|t|)
## peso 1.25825
                   0.30688
                              4.100 0.000473 ***
                              2.306 0.030903 *
## vef1 0.94792
                   0.41104
        0.11159
                   0.03432
                              3.251 0.003660 **
## vr
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 24.84 on 22 degrees of freedom
## Multiple R-squared: 0.9585, Adjusted R-squared: 0.9528
## F-statistic: 169.4 on 3 and 22 DF, p-value: 2.383e-15
```

Referências

He, Ziyang, Maolin Zhang, and Haozhe Zhang. 2016. "Data-Driven Research on Chemical Features of Jingdezhen and Longquan Celadon by Energy Dispersive x-Ray Fluorescence." Ceramics International 42 (4): 5123–29. https://doi.org/10.1016/j.ceramint.2015.12.030.